

BÁO CÁO ĐỒ ÁN CUỐI KỲ MÔN HỌC

XÂY DỰNG MÁY TÌM KIẾM CHUYÊN SÂU (VERTICAL SEARCH ENGINE)

Lĩnh Vực: Bài Viết, Hướng Dẫn & Tài Liệu Lập Trình IT (DevSeek)

Nhóm Sinh Viên Thực Hiện

Khoa Công Nghệ Thông Tin

Năm Học 2024 - 2025

TÓM TẮT ĐỒ ÁN

Báo cáo này trình bày thiết kế, hiện thực và đánh giá toàn diện hệ thống **DevSeek** - một Máy Tìm Kiếm Chuyên Sâu (Vertical Search Engine) tập trung vào lĩnh vực kiến thức, hướng dẫn và tài liệu học tập lập trình công nghệ thông tin (IT) bằng tiếng Việt. Hệ thống được triển khai qua 5 module cốt lõi: (1) Thu thập dữ liệu tự động với BeautifulSoup/requests tuân thủ robots.txt cùng tập dữ liệu chuẩn 122 bài viết IT chất lượng cao; (2) Tiền xử lý văn bản tiếng Việt sử dụng thư viện xử lý ngôn ngữ tự nhiên underthesea kết hợp với việc xây dựng Chỉ mục ngược (*Inverted Index*) hỗ trợ ghi nhận vị trí từ khóa và tần suất theo từng trường; (3) Bộ máy xử lý truy vấn và xếp hạng theo mô hình **Multi-Field TF-IDF** áp dụng trọng số ưu tiên cho Tiêu đề (x3.0) và Thẻ từ khóa (x2.5); (4) Giao diện Web Flask hiện đại với phong cách *Dark Mode Glassmorphism*, tính năng làm nổi bật từ khóa bằng thẻ <mark> và phân trang mượt mà; (5) Bộ kiểm thử đánh giá hệ thống trên 20 câu truy vấn chuẩn thực tế đạt độ chính xác trung bình **Precision@10 = 0.5450** và điểm số trung bình toàn cục **MAP = 0.7906** với thời gian phản hồi trung bình chỉ **48.24 ms**.

1. GIỚI THIỆU & LÝ DO CHỌN ĐỀ TÀI

1.1. Máy Tìm Kiếm Chuyên Sâu Là Gì?

Các máy tìm kiếm đa năng như Google hay Bing có khả năng lập chỉ mục hàng tỷ trang web trên toàn thế giới, đáp ứng nhu cầu tra cứu thông tin phổ quát. Tuy nhiên, khi lập trình viên hoặc sinh viên CNTT cần tìm kiếm các bài viết hướng dẫn chuyên sâu về một ngôn ngữ lập trình, một thuật toán cụ thể hay giải quyết lỗi code, kết quả từ các máy tìm kiếm chung thường bị phân tán, lẫn lộn với trang tin tức thương mại hoặc quảng cáo. **Máy tìm kiếm chuyên sâu (Vertical Search Engine)** tập trung thu thập, phân tích và lập chỉ mục dữ liệu thuộc duy nhất một lĩnh vực cụ thể, nhờ đó áp dụng được các luật tiền xử lý đặc thù (giữ lại từ khóa kỹ thuật C++, C#, NodeJS) và mang lại kết quả chuẩn xác nhất.

1.2. Mục Tiêu Đồ Án

Đồ án hướng đến việc rèn luyện toàn diện cả về lý thuyết lẫn kỹ năng thực chiến: hiểu rõ kiến trúc Crawler, tiền xử lý tách từ tiếng Việt, kỹ thuật xây dựng Inverted Index, thuật toán xếp hạng Multi-field TF-IDF và đánh giá định lượng bằng Precision@10, MAP.

2. KIẾN TRÚC HỆ THỐNG TỔNG THỂ

Hệ thống DevSeek được thiết kế theo kiến trúc đường ống (Pipeline Architecture) gồm 5 module liên kết thông qua cấu trúc dữ liệu JSON chuẩn hóa:

■ ■ ■ LƯỚING X ■ LÝ 5 MODULES DEVSEEK:

1. **Module 1 (Crawling)**: Thu th ■ p t ■ các trang IT & t ■ o b ■ d ■ li ■ u 122 bài vi ■ t -> articles.json

2. **Module 2 (Preprocessing & Indexing)**: Tách từ tiếng Việt với underthesea, loại stopwords -> Xây dựng Inverted Index lưu docID, vị trí và tần suất theo từ -> index.json

3. **Module 3 (Ranking)**: Xử lý truy vấn -> Tính điểm Multi-Field TF-IDF (Title x3.0, Tags x2.5, Content x1.0) -> Highlight từ khóa

4. **Module 4 (Web UI)**: Flask Backend + Giao diện Dark Mode Glassmorphism hiển thị SERP & phân trang

5. **Module 5 (Evaluation)**: Đánh giá 20 truy vấn chuẩn -> Tính toán Precision@10 & MAP

3. THIẾT KẾ CHI TIẾT & THUẬT TOÁN CÁC MODULES

3.1. Module 1: Thu Thập Dữ Liệu (Crawling)

Module thu thập dữ liệu (crawler/it_crawler.py) kết hợp 2 cơ chế: (1) Cào live với BeautifulSoup + requests tuân thủ nghiêm ngặt robots.txt; (2) Cơ chế Seed Data Generator tự động tạo bộ dữ liệu chuẩn 122 bài viết hướng dẫn lập trình chi tiết bằng tiếng Việt giúp đảm bảo hệ thống luôn ổn định không bị ảnh hưởng bởi lỗi mạng hay Cloudflare.

3.2. Module 2: Xử Lý Văn Bản & Xây Dựng Chỉ Mục (Inverted Index)

Do tiếng Việt có rất nhiều từ ghép (ví dụ: 'lập trình', 'hướng đối tượng'), chúng tôi sử dụng thư viện underthesea.word_tokenize để nhận diện từ ghép và nối bằng dấu gạch dưới (_), chuyển chữ thường và lọc stopwords. Danh sách các ký tự lập trình ngăn như C++, C#, AI, JS được bảo toàn.

Chỉ mục ngược được xây dựng ánh xạ từ khóa sang danh sách tài liệu, lưu tần suất tf, danh sách vị trí positions và tần suất theo trường field_tf (title, tags, content).

3.3. Module 3: Truy Vấn & Xếp Hạng Kết Quả (Multi-Field TF-IDF)

Điểm số độ liên quan giữa truy vấn Q và văn bản D được tính theo công thức Multi-Field TF-IDF:

$$\text{Score}(Q, D) = \sum [\text{IDF}(t) \times \text{WeightedTF}(t, D)]$$

Trong đó $\text{IDF}(t) = \ln((N + 1) / (\text{df}(t) + 1)) + 1.0$ (với $N=122$). Tần suất từ có trọng số: $\text{WeightedTF} = 3.0 \times \text{TF}_{\text{title}} + 2.5 \times \text{TF}_{\text{tags}} + 1.0 \times \text{TF}_{\text{content}}$. Hàm log chuẩn hóa Sublinear TF được áp dụng để tránh thiên lệch cho văn bản dài.

4. THỰC NGHIỆM & ĐÁNH GIÁ HỆ THỐNG (MODULE 5)

Để kiểm tra tính hiệu quả, chúng tôi xây dựng bộ 20 truy vấn benchmark chuẩn (benchmark_queries.json) kèm Ground Truth từ 5-10 tài liệu liên quan cho mỗi truy vấn. Các chỉ số đánh giá bao gồm Precision@10 và MAP (Mean Average Precision).

ID	Câu Hỏi Truy Vấn (Query)	P@10	AP	Thời Gian
----	--------------------------	------	----	-----------

q01	học python cơ bản cho người mới ...	0.3000	0.5461	805.07 ms
q02	thuật toán sắp xếp nhanh quickso...	0.2000	0.4075	10.61 ms
q03	khái niệm lập trình hướng đối tư...	0.7000	0.8260	5.63 ms
q04	hiểu rõ về async await trong jav...	0.3000	0.5648	10.06 ms
q05	hướng dẫn sử dụng git branch và ...	0.7000	0.9683	12.47 ms
q06	con trỏ pointer trong c++ và quả...	0.7000	1.0000	7.61 ms
q07	kiến trúc restful api là gì nguy...	0.2000	0.2857	3.28 ms
q08	docker là gì hướng dẫn dockerfil...	0.1000	0.1666	8.98 ms
q09	lệnh sql truy vấn select join gr...	0.6000	0.8571	8.05 ms
q10	phân tích dữ liệu bằng pandas và...	0.7000	0.9214	9.12 ms
TỔNG	TRUNG BÌNH TOÀN BỘ 20 TRUY VẤN	0.5450	0.7906	48.24 ms

Nhận xét kết quả:

- Chất lượng xếp hạng vượt trội (MAP = 0.7906):** Điểm số MAP gần 0.80 cho thấy hệ thống đưa các văn bản liên quan nhất lên ngay những vị trí đầu tiên ($k=1, 2, 3$) nhờ trọng số Tiêu đề x3.0 và Tags x2.5.
- Độ chính xác cao (Precision@10 = 0.5450):** Trong 10 kết quả đầu tiên, trung bình có hơn 5.4 tài liệu hoàn toàn khớp với chuẩn Ground Truth.
- Tốc độ phản hồi cực nhanh:** Thời gian tra cứu trung bình chỉ **48.24 ms** (và chỉ ~8 ms nếu không tính lần tải cold-start đầu tiên), hoàn toàn đáp ứng yêu cầu tra cứu thời gian thực.

5. KẾT LUẬN & HƯỚNG PHÁT TRIỂN

Đồ án đã xây dựng thành công trọn bộ hệ thống DevSeek qua đầy đủ 5 module yêu cầu từ thu thập, xử lý tách từ tiếng Việt với underthesea, xây dựng Inverted Index, xếp hạng Multi-field TF-IDF cho đến giao diện Web cao cấp và hệ thống kiểm thử tự động. Hướng phát triển trong tương lai: tích hợp Semantic Search (PhoBERT / Vector Embeddings), tự động cào dữ liệu định kỳ bằng Celery và cá nhân hóa kết quả theo lịch sử tra cứu của người dùng.